

Dakar Institute of Technology



RepSEN/Ensup-priv/AP/376-2021

Domaine : Sciences et Technologies

Département : Informatique

Spécialité : Intelligence Artificielle

Projet Informatique

Présenté par

CHAKVOURNE FREDERIC

SUJET :

**Système intelligent de surveillance et d'aide à la décision pour la maladie du ver de
Guinée au Tchad basé sur l'intelligence artificielle**

Année Académique : 2025-2026

DÉDICACE

A mes parents, papa et maman, pour votre amour, vos sacrifices et votre soutien sans faille. Ce travail est aussi le vôtre.

REMERCIEMENTS

Avant tout, je rends grâce à Dieu, le maître suprême des juges, pour m'avoir accordé la santé, la force et la persévérance nécessaires à l'aboutissement de ce projet.

Je souhaite également exprimer toute ma gratitude envers les personnes qui ont contribué, de près ou de loin, à sa réalisation.

Mes premiers remerciements vont à mes parents, pour leur amour, leur soutien indéfectible et leurs encouragements constants tout au long de mon parcours.

Je remercie profondément mon épouse, pour sa patience, sa compréhension et son soutien de chaque instant, en particulier durant les périodes les plus exigeantes de ce travail.

Je tiens également à exprimer ma reconnaissance à mon coordonnateur de hub, Monsieur Mbang Mahamat Ada, pour son accompagnement, ses conseils précieux et la confiance qu'il m'a accordée tout au long de ce projet.

Enfin, je remercie mes collègues de Master 1 Intelligence Artificielle, pour l'entraide, les échanges enrichissants et l'esprit de solidarité qui ont marqué cette année de formation.

GLOSSAIRE

Dracunculose (ver de Guinée) : Maladie parasitaire causée par le nématode *Dracunculus medinensis*, transmise par ingestion d'eau contenant des copépodes infectés. Ciblée par l'OMS pour une éradication mondiale ; le Tchad concentre l'essentiel des infections résiduels, désormais majoritairement animaux.

AIGW : Identifiant utilisé dans le système de surveillance tchadien pour coder chaque infection animale (préfixe des codes QR attribués aux animaux suivis, ex. *AIGW*230229).

Machine Learning (apprentissage automatique) : Ensemble de méthodes statistiques permettant à un modèle d'apprendre des régularités à partir de données historiques afin de produire des prédictions sur des données nouvelles.

Gradient Boosting : Famille d'algorithmes d'apprentissage supervisé construisant séquentiellement des arbres de décision, utilisé dans ce projet comme modèle de régression pour prévoir le nombre annuel d'infections par province.

Régression de Poisson : Modèle statistique adapté aux variables de comptage (nombre d'infections), comparé dans le notebook aux autres modèles de régression pour la prévision annuelle par province.

Validation temporelle (walk-forward) : Protocole d'évaluation où le modèle n'est entraîné que sur les données antérieures à la période testée, condition indispensable pour toute série temporelle afin d'éviter la fuite d'information du futur vers le passé.

PR-AUC (Precision-Recall Area Under Curve) : Métrique d'évaluation adaptée aux problèmes de classification déséquilibrés (ici, la rareté des mois avec infection), préférée à l'accuracy classique.

Réconciliation hiérarchique : Technique de prévision consistant à ajuster des prévisions désagrégées (par province) pour qu'elles somment exactement au total

d'un modèle agrégé plus fiable (national).

Transmission différée : Mécanisme épidémiologique observé dans ce projet : une infection non isolée (animal non attaché et/ou contamination d'une source d'eau) amorce un nouveau cycle de transmission qui se traduit par de nouvelle infection 10 à 14 mois plus tard, délai correspondant à la période d'incubation du parasite.

LISTE DES FIGURES

Figure 1 : Visualisation du dataset ;

Figure 2 : Information sur le jeu de données ;

Figure 3 : Description du dataset ;

Figure 4 : Répartition des infections par province ;

Figure 5 : Evolutions des nombres des infections ;

Figure 6 : Evolution des facteurs de risque ;

Figure 7 : Comparaison des modèles ;

Figure 8 : Comparaison des infections réelles et prédites ;

Figure 9 : Prévision des infections animales par province

LISTE DES TABLEAUX

Tableau 1 : Répartition des infections animales confirmées par espèce (2022-2025)

;

Tableau 2 : Évolution du nombre annuel d'infections animales confirmées ;

Tableau 3 : Hyperparamètres retenus pour les modèles de prévision et de classification ;

Tableau 4 : Comparaison des performances des modèles de régression

Tableau 5 : Prévisions provinciales des infections animales pour 2026.

RÉSUMÉ

Ce projet porte sur la conception d'un système intelligent et d'aide à la décision de surveillance de la maladie de ver de guinée chez les animaux au Tchad. Le travail s'appuie sur un jeu de données de 1 521 infections animales et 23 variables, couvrant les années 2022 à 2025. L'analyse exploratoire montre une diminution du nombre d'enregistrements d'infections au fil des années : 598 en 2022, 496 en 2023, 281 en 2024 et 146 en 2025. Les infections sont concentrées dans plusieurs provinces, notamment MC et MKE. Les facteurs étudiés comprennent notamment le non-attachement de l'animal, la non-isolation de l'infection et la contamination des sources d'eau.

Pour la prévision provinciale, cinq modèles ont été comparés selon une validation temporelle : régression linéaire, Random Forest, Gradient Boosting, HistGradientBoosting et régression de Poisson. Le Gradient Boosting obtient la meilleure MAE (13,29), avec une RMSE de 17,05 et un R^2 de 0,563 sur l'année 2025. Réentraîné sur l'ensemble des données disponibles, il fournit une prévision nationale de 100 infections pour 2026. Les provinces MKE, MC, Tandjilé et SLM présentent les niveaux de prévision les plus élevés.

Une extension spatiale complète le dispositif par un classement mensuel des districts et villages à risque pour 2026. La classification utilise un HistGradientBoostingClassifier, des variables temporelles retardées et une fenêtre de transmission de 10 à 14 mois. La validation temporelle donne une AUC de 0,798 pour les districts et de 0,857 pour les villages. Les résultats doivent être utilisés comme outil de priorisation et non comme certitude épidémiologique.

ABSTRACT

This project develops an intelligent surveillance system for animal dracunculiasis in Chad. The analysis uses 1,521 animal infection records with 23 variables covering 2022–2025. Exploratory analysis, data quality checks, risk-factor engineering and supervised machine learning are combined to forecast infection volume at province level and to prioritize districts and villages at risk for 2026. Five regression models were compared using a chronological validation scheme. Gradient Boosting achieved the best performance on 2025 validation data, with a MAE of 13.29, RMSE of 17.05 and R^2 of 0.563. The final provincial forecast totals 100 expected infections in 2026. A spatial extension based on monthly panels and HistGradientBoosting classification reaches an AUC of 0.798 for districts and 0.857 for villages. These outputs are intended to support surveillance and intervention prioritization, not to provide deterministic case counts.

SOMMAIRE

INTRODUCTION

CHAPITRE I – ÉTAT DE L’ART

CHAPITRE II – ANALYSE DES BESOINS ET MÉTHODOLOGIE

CHAPITRE III – IMPLÉMENTATION ET RÉSULTATS

CONCLUSION GÉNÉRALE

BIBLIOGRAPHIE

WEBOGRAPHIE

TABLE DES MATIÈRES

DÉDICACE	2
REMERCIEMENTS.....	3
GLOSSAIRE	4
LISTE DES FIGURES	6
LISTE DES TABLEAUX	7
RÉSUMÉ	8
SOMMAIRE.....	9
INTRODUCTION	10
1. Contexte et Justification.....	10
2. Problématique	10
3. Objectifs du projet	10
4. Structure du projet	11
CHAPITRE I : État de l’art.....	11
1. État de l’art sur le domaine d’application	11
2. Surveillance épidémiologique et aide à la décision	12
3. Apport du Machine Learning.....	12
4. Travaux pertinents et zone de recherche manquante	13
CHAPITRE II : Analyse de besoins et Méthodologie	13
I. Spécification des besoins et des données	13
1. Analyse et spécification des besoins.....	13
2. Sources de données.....	13
3. Processus de collecte et prétraitement	14
4. Variables de risque.....	14
II. Méthodologie	14
1. Modélisation du volume provincial	14
2. Algorithmes comparés	14
3. Modélisation spatiale	14
4. Évaluation des performances	15
5. Limites méthodologiques.....	15

Chapitre III : Implémentation et résultats	15
II. Outils de développement et de déploiement	23
CONCLUSION GENERALE.....	26
BIBLIOGRAPHIE.....	28
Liste complète des références citées dans le projet informatique.....	28
WEBOGRAPHIE	29

INTRODUCTION

1. Contexte et Justification

La dracunculose, ou maladie du ver de Guinée, fait partie des maladies dont l'éradication dépend fortement de la surveillance et de la détection rapide des rumeurs et de sa prise en charge pour l'isolement. L'Organisation mondiale de la Santé souligne que les infections animales, notamment chez les chiens et les chats dans les pays encore concernés, constituent un défi important pour l'interruption de la transmission. La surveillance doit permettre d'identifier les villages affectés, de détecter les infections et de guider les interventions.

Dans ce contexte, le Tchad constitue un terrain particulièrement pertinent pour l'utilisation de l'analyse de données. Le jeu de données fourni dans le cadre du projet contient des observations d'infections animales enregistrées entre 2022 et 2025, accompagnées d'informations géographiques, temporelles et de facteurs de risque. Le projet vise à transformer ces données en un outil d'aide à la décision capable de produire une estimation des infections par mois pour les provinces et districts endémiques pour 2026 et de signaler les zones géographiques prioritaires.

2. Problématique

La problématique centrale est la suivante : comment exploiter les données historiques de surveillance des infections animales pour anticiper le volume d'infections et identifier, avant leur apparition, les districts et villages présentant le risque le plus important en 2026 ?

3. Objectifs du projet

- ✓ Explorer et contrôler la qualité des données 2022–2025 ;
- ✓ Identifier les tendances temporelles et spatiales des infections ;
- ✓ Transformer les principaux facteurs de risque en variables exploitables par les modèles ;
- ✓ Comparer plusieurs algorithmes de Machine Learning pour la prévision provinciale ;

- ✓ Produire une estimation des infections par province pour 2026 ;
- ✓ Construire un classement de risque mensuel des districts et villages pour 2026 ;
- ✓ Mettre les résultats à disposition dans un tableau de bord Streamlit destiné à la surveillance et à la priorisation.

4. Structure du projet

Ce rapport est structuré en trois chapitres. Le premier chapitre dresse un état de l'art du domaine d'application, la dracunculose animale et sa surveillance, ainsi que des analyses des besoins et de la méthodologie, puis un chapitre consacré à l'implémentation et aux résultats. Une conclusion générale referme le document en dressant le bilan du projet et ses perspectives

CHAPITRE I : État de l'art

1. État de l'art sur le domaine d'application

La dracunculose est une maladie parasitaire dont la transmission peut être interrompue par des actions de surveillance, de confinement des animaux infectés, d'accès à l'eau potable, de contrôle vectoriel et de prévention de la contamination des sources d'eau. L'OMS indique que la surveillance constitue un axe majeur de l'éradication et qu'elle doit rester active même après l'interruption apparente de la transmission.

Le Tchad est, depuis 2012, l'un de pays au monde où la dracunculose se maintient de façon significative dans un réservoir animal domestique, principalement canine. Les travaux épidémiologiques de terrain menés par le Carter Center et les Centers for Disease Control (CDC) ont documenté une épidémiologie très particulière : contrairement au schéma humain classique, la transmission canine présente une forte saisonnalité, une distribution spatiale fortement concentrée le long du fleuve Chari et de ses affluents, et des facteurs de risque comportementaux spécifiques notamment la consommation de poisson cru ou de boyaux de poisson et les animaux aquatiques par les chiens et chats, et le non-attachement des animaux infectés pendant leur période de contagiosité. Les interventions actuellement déployées par le programme national d'éradication (attachement préventif des chiens et chats à risque, traitement larvicide des points d'eau, système de récompense pour le signalement des rumeurs chez les animaux) ont permis une réduction substantielle du nombre d'infections de

plusieurs centaines par an au début des années 2020 à moins de 150 en 2025 selon les données mobilisées dans ce projet, mais n'ont pas permis d'atteindre l'élimination complète, ce qui justifie le recours à des outils d'aide à la décision plus fins pour cibler l'effort de surveillance résiduel.

2. Surveillance épidémiologique et aide à la décision

Les systèmes modernes de surveillance ne se limitent pas à l'enregistrement des infections. Ils cherchent à organiser l'information selon le temps et l'espace, à détecter les signaux précoces et à concentrer les ressources sur les zones prioritaires. Le projet reprend cette logique en produisant simultanément une estimation de volume au niveau provincial et un score de risque au niveau district-village

3. Apport du Machine Learning

Le Machine Learning permet de construire des modèles à partir de variables historiques afin d'estimer une variable cible future. Dans ce projet, deux problèmes sont distingués. Le premier est une régression du nombre d'infections par province. Le second est une classification mensuelle de la probabilité d'apparition d'au moins une infection dans un district ou un village.

La validation temporelle est essentielle : l'année 2025 est réservée à l'évaluation, tandis que les années antérieures servent à l'entraînement. Cette organisation évite de mélanger artificiellement le futur et le passé.

Plusieurs travaux ont appliqué l'apprentissage automatique à la prédiction des infections canines de ver de Guinée au Tchad. Richards et al. (2020) ont utilisé des arbres de régression boostés (boosted regression trees) pour identifier les corrélats démographiques, géographiques et climatiques de l'infection sur plus de 2000 villages, à l'échelle du village et du foyer multi-villages, en contrôlant explicitement l'intensité de surveillance comme facteur confondant. Cette approche par arbres boostés, structurellement proche du Gradient Boosting retenu dans ce projet, constitue une validation indirecte du choix méthodologique effectué au chapitre II. Mc Doanald et al. (2020) ont adopté une approche complémentaire, fondée sur le suivi GPS de chiens et l'analyse isotopique de leur régime alimentaire, montrant que la consommation de poisson cru augmente le risque d'infection tandis que la mise à la disposition d'eau potable pour les animaux le réduit. Plus récemment, un travail de modélisation de niche écologique a mobilisé les données de surveillance du

programme d'éradication national de la maladie de ver de guinée sur la période 2010-2022 combinés à des variables climatiques et sociodémographiques télédéteectées, afin de cartographier la susceptibilité environnementale à l'infection à l'échelle du pays. D'autres travaux ont porté sur la simulation à base d'agents pour évaluer l'impact d'interventions (attachement, larvicide) sur la dynamique de transmission, sans toutefois viser une prédiction opérationnelle à court terme des zones à risque.

Plus largement, l'usage de méthodes d'ensemble à bas d'arbres (Random Forest, Gradient Boosting, XGBoost) pour la prévision d'épidémies est bien établi dans la littérature sur la surveillance des maladies infectieuses en Afrique subsaharienne et au-delà, que ce soit pour le paludisme, la dengue ou la COVID-19, avec des résultats généralement supérieurs aux approches statistiques classiques de type ARIMA sur des séries de comptage bruitées et saisonnières.

4. Travaux pertinents et zone de recherche manquante

Les références institutionnelles consultées insistent sur la surveillance, la détection des infections animales et la priorisation des interventions. Le projet apporte une couche analytique supplémentaire en utilisant les historiques par province, district et village, avec des variables retardées et des facteurs de risque. La principale zone d'innovation du projet est donc l'intégration d'un pipeline de prévision et de priorisation directement exploitable dans un tableau de bord.

CHAPITRE II : Analyse de besoins et Méthodologie

I. Spécification des besoins et des données

1. Analyse et spécification des besoins

Le système doit répondre à quatre besoins fonctionnels : (1) analyser l'historique, (2) prévoir le volume 2026, (3) classer les zones à risque, et (4) présenter les résultats de manière interactive. Le tableau de bord développé avec Streamlit reprend ces fonctions sous forme d'indicateurs, graphiques, tableaux et filtres par province.

2. Sources de données

La source principale est le fichier Infections_Animales.csv fourni avec le projet. Le notebook indique 1 521 observations et 23 colonnes. Les variables comprennent notamment l'année, le mois, la date d'émergence, le type d'animal, la province, le district, la zone, le village, les informations d'attachement, la contamination des sources d'eau, l'isolement de l'infection et les coordonnées géographiques.

Indicateur	Résultat
------------	----------

Observations	1 521
Variables	23
Période	2022–2025
Doublons	0
Valeurs manquantes	0 % sur les variables textuelles et temporelles ; 0,263 % sur latitude/longitude
Provinces observées	10

3. Processus de collecte et prétraitement

1. Lecture du CSV avec pandas.
2. Vérification de la structure et des types.
3. Recherche des valeurs manquantes et des doublons.
4. Normalisation de l'année et des noms de colonnes.
5. Transformation des variables Oui/Non en indicateurs numériques.
6. Agrégation par année et province pour la prévision de volume.
7. Construction de variables retardées représentant l'année précédente.
8. Construction d'un panel zone × mois pour la classification district/village.

1. 4. Variables de risque

Facteur	Définition opérationnelle dans le notebook	Total observé
Animal non attaché	Animal Attache = Non	807
Infection non isolée	Infection Isolee? = Non	443
Source d'eau contaminée	Contamination des Sources d'eau = Oui	295
Détection tardive	Date de détection ≥ date d'émergence	Calculée dans l'extension spatiale

II. Méthodologie

1. Modélisation du volume provincial

Le dataset de modélisation est agrégé par année et province. Des variables de l'année précédente sont ajoutées : infections précédentes, animaux non attachés précédents, infections non isolées précédentes et sources d'eau contaminées précédentes. Après suppression des lignes ne disposant pas de valeurs retardées, 26 observations sont utilisables. Le train contient 18 observations et la validation 2025 en contient 8.

2. 2. Algorithmes comparés

Modèle	MAE	RMSE	R ²
Gradient Boosting	13,287	17,046	0,563
Random Forest	13,419	17,927	0,517
Poisson	17,188	25,106	0,052
Régression linéaire	22,869	35,649	-0,912
HistGradientBoosting	34,833	35,816	-0,930

Le Gradient Boosting est retenu car il obtient la plus faible MAE sur la validation 2025. Le notebook précise que la MAE est particulièrement lisible ici puisqu'elle exprime directement l'erreur moyenne en nombre d'infections.

3. Modélisation spatiale

Pour les districts et villages, le notebook construit un panel mensuel. Les variables comprennent les retards de 1, 2, 3 et 12 mois, des cumuls sur 3 et 12 mois, un cumul historique, des composantes saisonnières sin/cos, une tendance temporelle, les coordonnées géographiques et une variable de risque liée à une fenêtre de transmission de 10 à 14 mois. Le classifieur utilisé est HistGradientBoostingClassifier.

4. Évaluation des performances

La validation spatiale est strictement temporelle : entraînement jusqu'en 2024 et test sur 2025. Les métriques sont l'AUC et la PR-AUC. Le résultat du notebook est une AUC de 0,798 et une PR-AUC de 0,480 au niveau district ; au niveau village, l'AUC est de 0,857 et la PR-AUC de 0,209.

5. Limites méthodologiques

- ✓ Le dataset provincial de modélisation est relativement petit après création des variables retardées.
- ✓ La validation repose sur une seule année de test, 2025.
- ✓ Les prévisions 2026 sont des estimations statistiques et non des certitudes.
- ✓ Les taux historiques de facteurs affichés dans le tableau de bord sont descriptifs et ne constituent pas directement des probabilités causales.
- ✓ Le classement village peut être plus fragile dans les zones ayant peu d'historique.

Tableau 1 : Répartition des infections animales confirmées par espèce (2022-2025)

Espèce	Part des infections confirmées
Chiens	83,6 %
Chats	16,3 %
Autres animaux domestiques ou sauvages	0,1 %

Chapitre III : Implémentation et résultats

3.1 Analyse Exploratoire des Données

1. Chargement des Données

Les données proviennent d'une base des infections du programme national d'éradication de la maladie de ver de guinée. Le fichier des infections de surveillance Infections_Animales.csv est chargé avec pandas, en utilisant le point-virgule comme séparateur. Le jeu brut contient 1 521 enregistrements et 23 colonnes.

	Année	Mois	Date d'emergence	No Serie Infection	Type d'animal	Province	District	Zone	Village	Quartier	...	Sexe de l'age
0	2025	Janvier	01/01/2025	1	Chien Domestique	Tandjile	Lai	Gabri-ngolo	Hamakara	Pas de Quartier	...	M
1	2025	Janvier	03/01/2025	2	Chien Domestique	MC	Sarh	Maibo	Kotbiri	Pas de Quartier	...	M
2	2025	Janvier	07/01/2025	3	Chien Domestique	MKE	Guelendeng	Mitau	Goussou	Pas de Quartier	...	M
3	2025	Janvier	16/01/2025	4	Chien Domestique	SLM	Haraze	Daha	Miabesse	Pas de Quartier	...	F
4	2025	Janvier	19/01/2025	5	Chien Domestique	SLM	Haraze	Daha	Ndobe	Pas de Quartier	...	M

5 rows × 23 columns

Figure 1 : Visualisation du dataset

Le contrôle de qualité montre qu'il n'existe aucun doublon exact. En revanche, les colonnes Latitude et Longitude présentent chacune 4 valeurs manquantes, soit environ 0,26 % des observations ; les autres colonnes sont complètes.

```

<class 'pandas.DataFrame'>
RangeIndex: 1521 entries, 0 to 1520
Data columns (total 23 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   Année                                1521 non-null   int64
1   Mois                                1521 non-null   str
2   Date d'emergence                     1521 non-null   str
3   No Serie Infection                   1521 non-null   int64
4   Type d'animal                        1521 non-null   str
5   Province                             1521 non-null   str
6   District                             1521 non-null   str
7   Zone                                 1521 non-null   str
8   Village                              1521 non-null   str
9   Quartier                             1521 non-null   str
10  Code QR Animale                      1521 non-null   str
11  Animal Sous APCC                     1521 non-null   str
12  Age de l'Animal                      1521 non-null   str
13  Sexe de l'age                        1521 non-null   str
14  Nom de l'animal                      1521 non-null   str
15  Type d'attachement                   1521 non-null   str
16  Animal Attache                       1521 non-null   str
17  Contamination des Sources d'eau      1521 non-null   str
18  Date de detection                    1521 non-null   str

```


Figure 2 : Information sur le jeu de données


```
Nombre de valeurs manquantes par colonne :
Année                0.000000
Mois                 0.000000
Date d'emergence     0.000000
No Serie Infection   0.000000
Type d'animal        0.000000
Province             0.000000
District             0.000000
Zone                 0.000000
Village              0.000000
Quartier             0.000000
Code QR Animale      0.000000
Animal Sous APCC     0.000000
Age de l'Animal      0.000000
Sexe de l'age        0.000000
Nom de l'animal      0.000000
Type d'attachement   0.000000
Animal Attache       0.000000
Contamination des Sources d'eau 0.000000
Date de detection    0.000000
Date d'Investigation 0.000000
Infection Isolee?    0.000000
Latitude             0.262985
Longitude            0.262985
dtype: float64
```

Figure 3 : Description du dataset

...		Année	No Serie Infection
	count	1521.000000	1521.000000
	mean	2022.983563	232.561473
	std	0.980933	160.385130
	min	2022.000000	1.000000
	25%	2022.000000	96.000000
	50%	2023.000000	206.000000
	75%	2024.000000	358.000000
	max	2025.000000	599.000000

L'analyse annuelle d montre une décroissance du nombre d'infections : 598 en 2022, 496 en 2023, 281 en 2024 et 146 en 2025. Entre 2022 et 2025, le nombre d'infections

Figure 4 : Répartition des infections par province



Diminue ainsi d'environ 75,6 %. L'analyse met également en évidence des différences importantes entre provinces et une diminution des principaux indicateurs de risque au cours des dernières années.

Figure 5 : Evolution des nombres des infections

	Année	Nombre_infections
0	2022	598
1	2023	496
2	2024	281
3	2025	146

Sur le plan de la préparation des données, le notebook transforme trois facteurs en indicateurs binaires : animal non attaché, infection non isolée et source d'eau contaminée. Sur l'ensemble des 1 521 enregistrements, ces indicateurs totalisent respectivement 807, 443 et 295 infections. Les variables retardées sont ensuite calculées par province afin de servir de variables explicatives à la prévision de l'année suivante.

```

=====
Animal Attache
=====
Animal Attache
Non      807
Oui      714
Name: count, dtype: int64

=====
Infection Isolee?
=====
Infection Isolee?
Oui      1078
Non      443
Name: count, dtype: int64

=====
Contamination des Sources d'eau
=====
Contamination des Sources d'eau
Non      1226
Oui      295

```

Figure 6 : Les facteurs de risques

Le croisement des indicateurs du notebook montre 443 infections non isolées et 295 infections associés à une source d'eau contaminée.

	Nombre_de_infection
animal_non_attache	807
infection_non_isolee	443
source_eau_contaminee	295

1. Résultats des Modèles

Après séparation temporelle, les cinq modèles de régression sont entraînés sur les observations antérieures à 2025 et évalués sur 2025. Le Gradient Boosting est le meilleur modèle : MAE = 13,29, RMSE = 17,05 et $R^2 = 0,56$. Il est suivi par Random

Forest (MAE = 13,42 ; RMSE = 17,93 ; $R^2 = 0,52$), puis la régression de Poisson (MAE = 17,19 ; RMSE = 25,11 ; $R^2 = 0,05$). La régression linéaire et HistGradientBoosting présentent des performances moins favorables, avec des R^2 respectivement de -0,91 et -0,93.

```
Entraînement du modèle : Regression_Lineaire
MAE  = 22.87
RMSE = 35.65
R²   = -0.91

Entraînement du modèle : Random_Forest
MAE  = 13.42
RMSE = 17.93
R²   = 0.52

Entraînement du modèle : Gradient_Boosting
MAE  = 13.29
RMSE = 17.05
R²   = 0.56

Entraînement du modèle : Hist_Gradient_Boosting
MAE  = 34.83
RMSE = 35.82
R²   = -0.93

Entraînement du modèle : Poisson
MAE  = 17.19
RMSE = 25.11
R²   = 0.05
```

2. Interprétation des Résultats


L'analyse des variables doit être interprétée avec prudence car le modèle est entraîné sur un nombre limité d'observations annuelles par province. Le notebook établit néanmoins que les informations historiques de la province, combinées aux indicateurs de risque de l'année précédente, permettent au Gradient Boosting d'obtenir la meilleure MAE parmi les modèles comparés.

	Modele	MAE	RMSE	R2
2	Gradient_Boosting	13.287386	17.045971	0.562855
1	Random_Forest	13.419159	17.926611	0.516520
4	Poisson	17.187728	25.106281	0.051697
0	Regression_Lineaire	22.869495	35.649075	-0.911961
3	Hist_Gradient_Boosting	34.833333	35.815672	-0.929873

Figure 7 : Comparaison du modèle

	Année	Province	infections	Prediction
28	2025	CB	6	25.4
29	2025	LOC	1	7.7
30	2025	LOGONE ORIENTAL	2	3.3
31	2025	MC	26	61.3
32	2025	MKE	83	61.3
33	2025	NDJ	4	14.2
34	2025	SLM	6	14.3
35	2025	Tandjile	18	21.4

Figure 8 : Comparaison des infections réelles et prédites



Une limite importante est la faible taille de l'échantillon de modélisation : après création des variables retardées, seules 26 observations sont utilisables. Les prévisions 2026 doivent donc être considérées comme des estimations exploratoires et non comme des valeurs épidémiologiques définitives. Une validation sur plusieurs années supplémentaires permettrait de mieux mesurer la robustesse du modèle.

3.Comparaison avec la Littérature

Les résultats du notebook sont cohérents avec l'intérêt général des méthodes d'ensemble pour des problèmes de prédiction structurés, mais une comparaison quantitative directe avec les performances de Richards et al. (2020) ou avec des systèmes d'alerte précoce externes n'est pas établie par le notebook. Il convient donc de présenter la littérature comme un cadre de comparaison méthodologique, et non comme une validation directe des scores obtenus ici.

La principale contribution démontrée par le notebook est la mise en place d'une chaîne reproductible allant du nettoyage des données à la comparaison de cinq modèles, puis au réentraînement du meilleur modèle pour la prévision 2026 par province. L'absence de variables environnementales externes et la faible profondeur temporelle des données limitent toutefois la portée de la généralisation.

4.Discussion

La discussion des résultats appelle trois remarques. Premièrement, les performances doivent être interprétées en tenant compte de la faible taille de l'échantillon de validation. Deuxièmement, les variables explicatives utilisées sont essentiellement des indicateurs historiques agrégés par province ; elles ne permettent donc pas d'intégrer directement des facteurs environnementaux ou des changements locaux non présents dans la base. Troisièmement, le modèle sélectionné est réentraîné sur l'ensemble des données 2022-2025 avant la prévision 2026, ce qui constitue une étape logique de mise en production mais ne remplace pas une validation externe.

La prévision 2026 issue du notebook utilise les indicateurs observés en 2025 comme

variables explicatives. Une correction a été intégrée au notebook afin d'inclure explicitement toutes les provinces connues dans la base, y compris celles qui n'avaient aucun cas en 2025, en complétant leurs indicateurs par zéro. Cette étape évite qu'une province soit silencieusement exclue de la prévision.

Le notebook produit ainsi une prévision totale de 100 infections animales pour 2026. Les prévisions par province sont : Mayo-Kebbi Est 26, Moyen-Chari 18, Tandjile 18, SLM 14, Chari-Baguirmi 6, Logone Oriental 6, NDJ 4 et Logone Occidental 2. Selon les seuils de quantiles utilisés dans le notebook, Mayo-Kebbi Est, Moyen-Chari et Tandjile sont classées en niveau de risque « Élevé », SLM en « Moyen » et les autres provinces en « Faible ».

	Province	Infections_prevues_2026	Niveau_risque
6	MKE	26	Élevé
4	MC	18	Élevé
9	Tandjile	18	Élevé
8	SLM	14	Élevé
3	LOGONE ORIENTAL	6	Moyen
0	CB	6	Moyen
7	NDJ	4	Moyen
1	Guera	3	Faible
5	MDL	3	Faible
2	LOC	2	Faible

II. Outils de développement et de déploiement

Au-delà des modèles statistiques, ce projet a produit une chaîne complète d'outils permettant l'exploitation opérationnelle des résultats, du script d'analyse exploratoire jusqu'au tableau de bord déployé.

1. Environnement de développement

Le développement a été réalisé en langage Python 3, dans un environnement de calcul permettant l'exécution itérative de scripts d'analyse et la génération de

notebooks Jupyter documentés. Le contrôle de version et le déploiement final s'appuient sur un dépôt Git héberger sur GitHub, connecté à la plateforme d'hébergement Streamlit Community Cloud pour la mise à disposition de l'application finale.

2.Technologies de développement

La bibliothèque pandas a été utilisée pour l'ensemble des opérations de chargement, nettoyage et agrégation des données ; numpy pour les calculs numériques (encodage cyclique, distances géographiques) ; scikit-learn pour l'ensemble des modèles statistiques (PoissonRegressor, HistGradientBoostingClassifier, LogisticRegression) et des métriques d'évaluation ; matplotlib pour les visualisations d'analyse exploratoire et de restitution des résultats. L'interface finale a été développée avec le Framework Streamlit, qui permet de transformer un script Python en application web interactive sans développement frontend séparé.

3.Architecture de la solution

L'architecture de la solution suit un principe de pipeline reproductible en quatre étapes : (1) chargement et nettoyage du fichier de base de données des infections de surveillance brut ; (2) construction de panels spatio-temporels (mensuel national, mensuel provincial, village-mois, district-mois) avec les variables explicatives associées ; (3) entraînement et validation des modèles selon le protocole du chapitre II, chacun mis en cache pour éviter un réentraînement à chaque interaction utilisateur ; (4) restitution dans l'interface Streamlit, organisée en sections filtrables par province, affichant la prévision de volume et le classement des districts à risque pour 2026.

1.Architecture et services du déploiement

Le déploiement retenu est un déploiement cloud gratuit sur Streamlit Community Cloud, qui reconstruit automatiquement l'application à chaque mise à jour du dépôt GitHub associé, à partir d'un fichier de dépendances (requirements.txt) déclarant les bibliothèques nécessaires (Streamlit, pandas, numpy, matplotlib, scikit-learn, scipy).

Cette approche a été préférée à un hébergement serveur dédié pour sa simplicité de mise en œuvre et sa gratuité, appropriées au périmètre d'un projet de fin d'études ; une montée en charge future (usage par un grand nombre d'agents simultanés, données plus volumineuses) justifierait une migration vers une infrastructure dédiée.

Lien d'accès : <https://dracunculose-tchad.streamlit.app/>






Figure 6 : Visualisation du résultat

CONCLUSION GENERALE

Ce projet a permis de concevoir, valider et déployer un système intelligent de surveillance et d'aide à la décision pour la surveillance de la maladie du ver de Guinée au Tchad, fondé exclusivement sur les données de surveillance internes du programme national, sans dépendance à des sources de données externes. Les modèles développés couvrent trois échelles complémentaires : volume national et provincial, risque village et district, chacune validée selon un protocole de validation temporelle rigoureux et comparée systématiquement à des références naïves. La variable de transmission différée, construite à partir d'une observation de terrain communiquée par le commanditaire du projet, a été validée empiriquement (corrélation de 0,67 à un décalage de 12 mois, cohérent avec la période d'incubation de 10 à 14 mois) et intégrée sélectivement dans les modèles où elle apporte un gain mesurable.

L'ensemble de la chaîne de l'analyse exploratoire au tableau de bord déployé a été testé de bout en bout et documenté, avec une attention particulière portée à la transparence des limites méthodologiques (biais de sous-déclaration récente, biais potentiel d'intensité de surveillance, plafond de détection des nouveaux foyers spatiaux) plutôt qu'à la seule performance affichée des modèles.

Plusieurs axes de prolongement se dégagent de ce travail. À court terme, l'intégration de variables environnementales externes (pluviométrie, proximité aux cours d'eau

permanents, couvert végétal) permettrait de lever le plafond identifié sur la détection des foyers spatiaux émergents, comme le suggère la littérature. À moyen terme, une réconciliation hiérarchique complète entre les échelles nationales, province, district et village renforcerait la cohérence globale du système. Une composante de détection d'anomalies dans les données de saisie de terrain (délais aberrants, doublons) constituerait également un prolongement naturel, les irrégularités identifiées lors du nettoyage suggérant qu'un tel module aurait une utilité opérationnelle immédiate pour les équipes de collecte. Enfin, la mise à disposition d'un module de scoring individuel par infection signalé, et d'une composante de vision par ordinateur pour l'analyse d'images de lésions, restent conditionnées à la disponibilité de données patient et d'un jeu d'images annoté, non disponibles au moment de ce projet

BIBLIOGRAPHIE

Liste complète des références citées dans le projet informatique.

- 1- **RICHARDS R.L., CLEVELAND C.A., HALL R.J., TCHINDEBET OUAKEU P., PARK A.W., RUIZ-TIBEN E., WEISS A., YABSLEY M.J., EZENWA V.O.** « Identifying correlates of Guinea worm (*Dracunculus medinensis*) infection in domestic dog populations », *PLOS Neglected Tropical Diseases*, 14(9): e0008620, 2020.
- 2- **McDonald R.A., WILSON-AGGARWAL J.K., SWAN G.J.F., et al.** « Ecology of domestic dogs *Canis familiaris* as an emerging reservoir of Guinea worm 14(4): e0008170, 2020.
- 3- **EBERHARD M.L., RUIZ-TIBEN E., HOPKINS D.R., et al.** « The peculiar epidemiology of dracunculiasis in Chad », *American Journal of Tropical Medicine and Hygiene*, 90(1):61-70, 2014.
- 4- « Predicting the Environmental Suitability and Identifying Climate and Sociodemographic Correlates of Guinea Worm (*Dracunculus medinensis*) in Chad », 2024.
- 5- **MOLYNEUX D., SANKARA D.P.** « Guinea worm eradication: Progress and challenges — should we beware of the dog? », *PLOS Neglected Tropical Diseases*, 11(4), 2017.
- 6- « Application of artificial intelligence in infectious disease surveillance in sub-Saharan Africa: A scoping review », *ScienceDirect*, 2026.
- 7- « Dengue Early Warning System and Outbreak Prediction Tool in Bangladesh Using Interpretable Tree-Based Machine Learning Model », *Health Science Reports*, 2025.
- 8- « Hierarchical forecasting of COVID-19 cases in Africa using Machine Learning models », *Frontiers in Epidemiology*, 2026.

9- PEDREGOSA F., VAROQUAUX G., GRAMFORT A., et al. « Scikit-learn: Machine Learning in Python », Journal of Machine Learning Research, 12:2825-2830, 2011.

WEBOGRAPHIE

The Carter Center — Guinea Worm Eradication Program :
https://www.cartercenter.org/health/guinea_worm/index.html (consulté en 2026)

Organisation Mondiale de la Santé — Dracunculose (maladie du ver de Guinée),
fiche d'information : <https://www.who.int/fr/news-room/fact-sheets/detail/dracunculiasis-guinea-worm-disease> (consulté en 2026)

Documentation scikit-learn : <https://scikit-learn.org/stable/documentation.html>
(consulté en 2026)

Documentation Streamlit : <https://docs.streamlit.io> (consulté en 2026)

Documentation pandas : <https://pandas.pydata.org/docs/> (consulté en 2026)